



Nama : Muhammad Dhiauddin

NIM : 25917024

Program : Magister Informatika

Konsentrasi : Sains Data Profesional

Mata Kuliah : Pemodelan Kausal

Tugas : Tugas Pertemuan 8 dan 9

Github : <https://github.com/Mudhya19/Project-Causal-Discovery-PC-Algorithm-vs-GES.git>

Kaggle : <https://www.kaggle.com/datasets/uciml/pima-indians-diabetes-database>

## Laporan Proyek Causal Discovery: PC Algorithm vs GES

### 1. Pendahuluan

Diabetes melitus tipe 2 merupakan salah satu penyakit metabolik kronis dengan prevalensi tertinggi di dunia. World Health Organization (WHO) mencatat lebih dari 422 juta orang menderita diabetes, dengan sebagian besar beban penyakit berada di negara berkembang. Kemampuan untuk memahami **faktor kausal** - bukan sekadar faktor yang berkorelasi - sangat penting agar intervensi kesehatan dapat dirancang secara lebih efektif. Sebagai contoh, mengetahui bahwa penurunan BMI secara *kausal* menurunkan risiko diabetes memberikan justifikasi yang lebih kuat untuk program penurunan berat badan dibandingkan sekadar mengetahui bahwa BMI dan diabetes berkorelasi positif.

Pendekatan *causal discovery* memungkinkan kita memperoleh struktur kausal secara *data-driven* dari data observasional, tanpa memerlukan eksperimen terkontrol (RCT). Salah satu algoritma yang paling banyak digunakan adalah **PC Algorithm** (Spirtes et al., 2000), yang bekerja dengan menjalankan serangkaian uji independensi kondisional (CI test) untuk membangun *Completed Partially Directed Acyclic Graph* (CPDAG).

**Pertanyaan kausal utama yang dirumuskan dalam studi ini adalah:**

"Apakah Indeks Massa Tubuh (BMI) dan kadar glukosa darah secara kausal mempengaruhi risiko diabetes (Outcome), atau hubungan tersebut dijematani atau dikonfound oleh variabel lain seperti usia (Age) dan riwayat kehamilan (Pregnancies)?"

Dataset yang digunakan adalah Pima Indians Diabetes Database yang bersumber dari National Institute of Diabetes and Digestive and Kidney Diseases (NIDDK), tersedia secara publik di



Kaggle. Dataset ini mencatat pengukuran medis dari 768 wanita keturunan suku Pima Indian berusia minimal 21 tahun.

## 2. Metode

### 2.1 Deskripsi Variabel

Dataset terdiri atas 9 variabel dengan tipe data yang dijelaskan pada tabel berikut.

Output R:

```
Dimensi dataset: 768 baris x 9 kolom

| Variabel | Tipe_Data |
| :--- | :--- |
| Pregnancies | numeric |
| Glucose | numeric |
| BloodPressure | numeric |
| SkinThickness | numeric |
| Insulin | numeric |
| BMI | numeric |
| DiabetesPedigreeFunction | numeric |
| Age | numeric |
| Outcome | numeric |
```

### 2.2 Eksplorasi dan Persiapan Data

#### 2.2.1 Pembacaan Data dan Statistik Deskriptif Awal


Output R:

```
Statistik Deskriptif Awal (Sebelum Preprocessing)

| | Min. | 1st Qu. | Median | Mean | 3rd Qu. | Max. |
| :--- | :--- | :--- | :--- | :--- | :--- | :--- |
| Pregnancies | 0.00 | 1.00 | 3.00 | 3.85 | 6.00 | 17.00 |
| Glucose | 0.00 | 99.00 | 117.00 | 120.89 | 140.25 | 199.00 |
| BloodPressure | 0.00 | 62.00 | 72.00 | 69.11 | 80.00 | 122.00 |
| SkinThickness | 0.00 | 0.00 | 23.00 | 20.54 | 32.00 | 99.00 |
```



|                          |       |       |       |       |        |        |  |
|--------------------------|-------|-------|-------|-------|--------|--------|--|
| Insulin                  | 0.00  | 0.00  | 30.50 | 79.80 | 127.25 | 846.00 |  |
| BMI                      | 0.00  | 27.30 | 32.00 | 31.99 | 36.60  | 67.10  |  |
| DiabetesPedigreeFunction | 0.08  | 0.24  | 0.37  | 0.47  | 0.63   | 2.42   |  |
| Age                      | 21.00 | 24.00 | 29.00 | 33.24 | 41.00  | 81.00  |  |
| Outcome                  | 0.00  | 0.00  | 0.00  | 0.35  | 1.00   | 1.00   |  |



2.2.2 Penanganan Missing Values

Lima variabel mengandung nilai 0 yang secara fisiologis tidak mungkin terjadi: Glucose (glukosa 0 tidak mungkin pada individu hidup), BloodPressure (tekanan darah diastolik 0 berarti kematian klinis), SkinThickness (ketebalan kulit trisep 0 tidak mungkin), Insulin (kadar insulin 0 sangat tidak realistis kecuali dalam kondisi patologis ekstrem), dan BMI (BMI 0 tidak mungkin pada manusia). Nilai-nilai ini merupakan *missing values* yang dikodekan sebagai 0, kemungkinan akibat keterbatasan sistem pencatatan medis pada era pengumpulan data.

Output R:

|                                                   |           |            |  |
|---------------------------------------------------|-----------|------------|--|
| Jumlah dan Persentase Missing Values per Variabel |           |            |  |
| Variabel                                          | Jumlah NA | Persen (%) |  |



|                                    |
|------------------------------------|
| :---   :---:   :---:               |
| Pregnancies   0   0.0              |
| Glucose   5   0.7                  |
| BloodPressure   35   4.6           |
| SkinThickness   227   29.6         |
| Insulin   374   48.7               |
| BMI   11   1.4                     |
| DiabetesPedigreeFunction   0   0.0 |
| Age   0   0.0                      |
| Outcome   0   0.0                  |

**Justifikasi Strategi Imputasi - Median Imputation:** Dipilih median imputation karena (1) median lebih robust terhadap distribusi skewed dan outlier dibandingkan mean; (2) variabel medis seperti Insulin dan SkinThickness memiliki distribusi yang right-skewed sehingga mean akan overestimate nilai sentral; (3) sederhana, dapat direproduksi, dan tidak menambah variansi buatan.

**Output R:**

|                                             |  |
|---------------------------------------------|--|
| Nilai Median yang Digunakan untuk Imputasi: |  |
| Variabel   Median                           |  |
| :---   :---:                                |  |
| Glucose   117.0                             |  |
| BloodPressure   72.0                        |  |
| SkinThickness   29.0                        |  |
| Insulin   125.0                             |  |
| BMI   32.3                                  |  |
| Verifikasi - Total NA setelah imputasi: 0   |  |

**2.2.3 Penanganan Mixed Data: Diskretisasi**

Dataset ini merupakan mixed-type data (8 variabel kontinu + 1 variabel biner diskrit). Strategi yang dipilih adalah diskretisasi menggunakan metode quantile (3 bin). Metode quantile dipilih karena: (a) memastikan distribusi observasi yang relatif seimbang di setiap bin, mengurangi risiko *sparse cells* yang melemahkan uji statistik; (b) tidak mengasumsikan distribusi tertentu sehingga cocok untuk variabel medis yang umumnya skewed.



**Nama CI Test:** G-Squared Test (ekivalen dengan Mutual Information Test), yaitu uji statistik yang mengukur apakah dua variabel diskrit saling bebas diberikan sekumpulan variabel kondisional.

**Output R:**

```
Type Data Setelah Diskretisasi:

| Variabel | Tipe_Data |
| :--- | :--- |
| Pregnancies | factor |
| Glucose | factor |
| BloodPressure | factor |
| SkinThickness | factor |
| Insulin | factor |
| BMI | factor |
| DiabetesPedigreeFunction | factor |
| Age | factor |
| Outcome | factor |

Level Variabel Setelah Diskretisasi:

| Variabel | Level_Kategori |
| :--- | :--- |
| Pregnancies | [0,5.66667] | (5.66667,11.3333] | (11.3333,17] |
| Glucose | [44,95.6667] | (95.6667,147.333] | (147.333,199] |
| BloodPressure | [24,56.6667] | (56.6667,89.3333] | (89.3333,122] |
| SkinThickness | [7,37.6667] | (37.6667,68.3333] | (68.3333,99] |
| Insulin | [14,291.333] | (291.333,568.667] | (568.667,846] |
| BMI | [18.2,34.5] | (34.5,50.8] | (50.8,67.1] |
| DiabetesPedigreeFunction | [0.078,0.858667] | (0.858667,1.63933] | (1.63933,2.42] |
| Age | [21,41] | (41,61] | (61,81] |
| Outcome | Negatif | Positif |
```



### 2.3 Algoritma PC-Stable

Algoritma PC-Stable adalah varian *order-independent* dari PC Algorithm yang bekerja dalam dua fase utama:

- 1. Fase Skeleton:** Dimulai dari graf lengkap, setiap pasang variabel diuji apakah saling bebas secara kondisional. Jika ditemukan *separating set*, maka edge dihapus.
- 2. Fase Orientasi:** Edge yang tersisa diorientasikan menggunakan *Meek Rules* (orientasi dimulai dari deteksi v-structures, dilanjutkan dengan rules untuk menghindari siklus).

Parameter yang digunakan: CI Test  $m_i$  (G-Squared), nilai  $\alpha$  0.01 dan 0.05.

### 3. Hasil

#### 3.1 Statistik Deskriptif Pasca Preprocessing

Output R:

| Statistik Deskriptif Setelah Imputasi (Variabel Kontinu) |        |        |        |        |        |        |       |
|----------------------------------------------------------|--------|--------|--------|--------|--------|--------|-------|
| Min                                                      | Q1.25% | Median | Mean   | Q3.75% | Max    | SD     |       |
| :---                                                     | :---   | :---   | :---   | :---   | :---   | :---   | :---  |
| Pregnancies                                              | 0.00   | 1.00   | 3.00   | 3.85   | 6.00   | 17.00  | 3.37  |
| Glucose                                                  | 44.00  | 99.75  | 117.00 | 121.66 | 140.25 | 199.00 | 30.44 |
| BloodPressure                                            | 24.00  | 64.00  | 72.00  | 72.39  | 80.00  | 122.00 | 12.10 |
| SkinThickness                                            | 7.00   | 25.00  | 29.00  | 29.11  | 32.00  | 99.00  | 8.79  |
| Insulin                                                  | 14.00  | 121.50 | 125.00 | 140.67 | 127.25 | 846.00 | 86.38 |
| BMI                                                      | 18.20  | 27.50  | 32.30  | 32.46  | 36.60  | 67.10  | 6.88  |
| DiabetesPedigreeFunction                                 | 0.08   | 0.24   | 0.37   | 0.47   | 0.63   | 2.42   | 0.33  |
| Age                                                      | 21.00  | 24.00  | 29.00  | 33.24  | 41.00  | 81.00  | 11.76 |






3.2 Causal Discovery: Algoritma PC-Stable

3.2.1 PC-Stable dengan  $\alpha = 0.01$

CPDAG: PC-Stable ( $\alpha = 0.01$ )



Output R:

```
==== PC-Stable (alpha = 0.01) ====
Edge berarah : 2
Edge tdk berarah: 2
Total edge : 4


Edge berarah:
  from    to
[1,] "Insulin" "Glucose"
[2,] "Outcome" "Glucose"

Edge tidak berarah (pasangan unik):
  [1,] [2]
[1,] "Age" "Pregnancies"
[2,] "BMI" "SkinThickness"
```



3.2.2 PC-Stable dengan  $\alpha = 0.05$

CPDAG: PC-Stable ( $\alpha = 0.05$ )



Output R:


```
==== PC-Stable (alpha = 0.05) ====  
Edge berarah : 2  
Edge tdk berarah: 3  
Total edge : 5  
  
Edge berarah:  
  from      to  
[1,] "Pregnancies" "Age"  
[2,] "BloodPressure" "Age"  
  
Edge tidak berarah (pasangan unik):  
  [1]  [2]  
[1,] "Glucose" "Insulin"  
[2,] "Glucose" "Outcome"
```

[3,] "BMI" "SkinThickness"

### 3.2.3 Score-Based Algorithm: Hill-Climbing (Alternatif GES)

Algoritma Score-Based bekerja dengan mengeksplorasi ruang pencarian DAG secara rakus (greedy search) untuk menemukan graf yang memaksimalkan fungsi skor goodness-of-fit. Kita menggunakan parameter skor "bic" (Bayesian Information Criterion) yang memberikan penalti pada kompleksitas graf untuk mencegah overfitting.

#### CPDAG: Hill-Climbing (Score = BIC)



#### Output R:

```
=== Hill-Climbing (BIC) ===  
Edge berarah : 0  
Edge tdk berarah: 6  
Total edge : 6  
  
Edge tidak berarah (pasangan unik):  
[1] [2]  
[1,] "Age" "Pregnancies"  
[2,] "Outcome" "Pregnancies"  
[3,] "Glucose" "Insulin"  
[4,] "Glucose" "Outcome"
```



[5,] "Age" "BloodPressure"

[6,] "BMI" "SkinThickness"

3.2.4 Perbandingan Algoritma: PC-Stable vs Hill-Climbing

Output R:

|                                                                 |                        |                        |               |
|-----------------------------------------------------------------|------------------------|------------------------|---------------|
| Perbandingan Analisis: PC-Stable (Sensitivity) vs Hill-Climbing |                        |                        |               |
| Kriteria                                                        | PC-Stable (alpha=0.01) | PC-Stable (alpha=0.05) | Hill-Climbing |
| :---                                                            | :---:                  | :---:                  | :---:         |
| Metode Pendekatan                                               | Constraint-Based       | Constraint-Based       | Score-Based   |
| Parameter / Skor                                                | alpha = 0.01           | alpha = 0.05           | BIC           |
| Total Edge                                                      | 4                      | 5                      | 6             |
| Edge Berarah (->)                                               | 2                      | 2                      | 0             |
| Edge Tidak Berarah (-)                                          | 2                      | 3                      | 6             |
| Skor BIC Graf                                                   | -3870.30               | -3881.42               | -3841.01      |

Tabel perbandingan di atas menjawab instruksi eksperimen dari beberapa sudut pandang:

1. **Sensitivity Analysis PC:** Terlihat jelas bahwa pelanggaran ambang batas independensi statistik membuat graf menjadi lebih dense.
2. **Kekuatan Algoritma Score-Based (HC/GES):** Algoritma berbasis skor mengevaluasi keseluruhan struktur secara global menggunakan BIC. Skor BIC yang lebih tinggi (lebih mendekati nol) menunjukkan struktur graf yang secara statistik lebih didukung oleh sebaran data.

3.3 Estimasi Efek Kausal: BMI -> Outcome

Berdasarkan hasil CPDAG dan pengetahuan domain medis, didefinisikan DAG berannotasi pakar (expert-refined DAG) untuk identifikasi formal menggunakan paket dagitty.

Output R:

|                                                             |
|-------------------------------------------------------------|
| Ancestors dari BMI: BMI, Age                                |
| Descendants dari BMI: BMI, SkinThickness, Outcome           |
| Minimal Backdoor Adjustment Set untuk P(Outcome   do(BMI)): |
| { Glucose, Pregnancies }                                    |



{ Age }

Minimal Backdoor Adjustment Set untuk  $P(\text{Outcome} \mid \text{do}(\text{Glucose}))$ :

{ BMI, Pregnancies }

{ Age }

Efek  $P(\text{Outcome} \mid \text{do}(\text{BMI}))$  identifiable via backdoor? TRUE

Efek  $P(\text{Outcome} \mid \text{do}(\text{Glucose}))$  identifiable via backdoor? TRUE

Regresi Logistik Naif vs. Backdoor Adjusted

Output R:

Koefisien Model Adjusted (BMI + Backdoor)

|             | Estimate | Std. Error | z value | Pr(> z ) |
|-------------|----------|------------|---------|----------|
| (Intercept) | -8.9038  | 0.6868     | -12.965 | 0        |
| BMI         | 0.0923   | 0.0146     | 6.306   | 0        |
| Glucose     | 0.0372   | 0.0035     | 10.772  | 0        |
| Pregnancies | 0.1380   | 0.0272     | 5.076   | 0        |

Perbandingan Odds Ratio BMI terhadap Outcome: Naif vs. Adjusted

| Model                                         | OR (BMI) | 95% CI (Bawah) | 95% CI (Atas) | p-value | AIC   |
|-----------------------------------------------|----------|----------------|---------------|---------|-------|
| Naif (BMI saja)                               | 1.108    | 1.081          | 1.136         | 0       | 920.6 |
| Adjusted (BMI + Glucose+Pregnancies)          | 1.097    | 1.066          | 1.129         | 0       | 733.5 |
| Full Adj. (BMI + Age + Pregnancies + Glucose) | 1.098    | 1.067          | 1.130         | 0       | 733.9 |

Perbandingan Odds Ratio Glucose terhadap Outcome: Naif vs. Adjusted

| Model                                | OR (Glucose) | 95% CI (Bawah) | 95% CI (Atas) | p-value | AIC   |
|--------------------------------------|--------------|----------------|---------------|---------|-------|
| Naif (Glucose saja)                  | 1.041        | 1.034          | 1.048         | 0       | 797.6 |
| Adjusted (Glucose + BMI+Pregnancies) | 1.038        | 1.031          | 1.045         | 0       | 733.5 |

## 4. Interpretasi dan Diskusi

### 4.1 Analisis Edge Spesifik

- 1.Edge 1: Glucose - Outcome:** Edge ini merupakan temuan paling kuat dan konsisten. Secara medis: kadar glukosa plasma  $\geq 200$  mg/dL adalah biomarker utama diagnosis diabetes (ADA, 2023). Orientasi yang paling masuk akal adalah Glucose  $\rightarrow$  Outcome.
- 2.Edge 2: BMI - SkinThickness:** Keduanya mengukur adipositas dari sudut pandang berbeda. Mengapa edge ini bisa tidak berarah? Keduanya mungkin memiliki *common cause* laten (gaya hidup), sehingga tanpa observasi variabel ini, algoritma kekurangan informasi *v-structure* untuk menentukan arah.
- 3.Edge 3: Age - Pregnancies:** Secara temporal, usia mendahului kehamilan, sehingga orientasi Age  $\rightarrow$  Pregnancies adalah yang paling rasional secara kausalitas.

### 4.2 Evaluasi Tiga Asumsi Kausal

- 1. Causal Markov Condition:** Mendukung asumsi (mekanisme biologis terlokalisasi). Meragukan asumsi (sistem tubuh saling terintegrasi rumit sehingga "blanket kausal" jarang bersifat sempurna).
- 2. Faithfulness:** Risiko pelanggaran berat ada pada *Insulin dan Outcome*. Insulin menurunkan glukosa (protektif) tapi level insulin tinggi juga tanda resistensi (destruktif). Kedua jalur ini bisa saling membatalkan persis secara statistik (*cancellation effect*).
- 3. Causal Sufficiency:** Jelas dilanggar. Faktor *Gaya Hidup (Diet, Aktivitas Fisik)*, *Faktor Genetik*, dan *Status Sosial-Ekonomi* tidak diobservasi, sehingga model akan tetap memiliki *spurious edges* akibat confounding laten.

### 4.3 Perbedaan Constraint-based (PC) vs Score-based (HC/GES)

- 1.Constraint-Based (PC Algorithm):** Sangat bergantung pada keandalan uji statistik independensi. Pada dataset medis ini, ukuran tabel kontingensi *sparse* menurunkan *power* statistik sehingga rentan terhadap *false positive* jika  $\alpha$  diperbesar.
- 2.Score-Based (HC / GES):** Mengeksplorasi ruang DAG untuk memaksimalkan kecocokan global (BIC). Secara empiris, HC lebih *robust* memecahkan ambiguitas arah.

### 4.4 Pemilihan Graf yang Paling Dipercaya

Rekomendasi jatuh pada **Hill-Climbing (BIC)** atau **PC-Stable** ( $\alpha = 0.01$ ) berlandaskan: (1) Kontrol False Discovery Rate yang ketat mengurangi kebetulan statistik, dan (2) Prinsip *Parsimoni Kausal* (lebih baik mulai dari graf sederhana konservatif).

#### 4.5 Interpretasi Efek Kausal

Perbandingan  $OR_{Naif}$  vs  $Adjusted$  mengungkap bias. Pada model BMI, nilai  $OR_{adjusted} < OR_{naive}$ , mengindikasikan adanya **positive confounding**: Umur berkorelasi positif dengan BMI dan Outcome, sehingga tanpa kontrol umur, efek BMI tampak jauh lebih besar (1.108) dari yang sebenarnya (1.097).

#### 4.6 Expert Knowledge untuk Orientasi Edge Ambigu (Bonus)

Berdasarkan *expert knowledge* medis (Guyton & Hall, 2021):

1. **Glucose** → **Insulin**: Secara fisiologis, peningkatan glukosa memicu pankreas mensekresi insulin.
2. **Age** → **BMI**: Perlambatan metabolisme usia lanjut meningkatkan BMI (usia tak bisa dipengaruhi BMI).
3. **BMI** → **SkinThickness**: Peningkatan lemak total tercermin pada tebal lipatan kulit.

### 5. Kesimpulan

1. **Struktur Kausal**: PC-Stable dan HC berhasil mengidentifikasi bahwa edge antara Glucose dan Outcome muncul konsisten dan robust.
2. **Sensitivity Analysis**:  $\alpha = 0.01$  direkomendasikan untuk menekan *false positives* akibat *sparse data*.
3. **Estimasi Efek Kausal**: Penyesuaian *backdoor* membuktikan bahwa intervensi langsung pada BMI memiliki efek yang *confounded* oleh Usia.
4. **Asumsi**: *Causal sufficiency* jelas dilanggar karena absennya data Gaya Hidup. Penambahan variabel ini direkomendasikan pada studi mendatang.

### Referensi

1. Chickering, D. M. (2002). Optimal Structure Identification with Greedy Equivalence Search. *Journal of Machine Learning Research*, 3, 507–554.
2. Colombo, D., & Maathuis, M. H. (2014). Order-independent constraint-based causal structure learning. *JMLR*, 15(1), 3741–3782.
3. Glymour, C., Zhang, K., & Spirtes, P. (2019). Review of Causal Discovery Methods Based on Graphical Models. *Frontiers in Genetics*, 10, 524.
4. Guyton, A. C., & Hall, J. E. (2021). *Textbook of Medical Physiology* (14th ed.). Elsevier.
5. Heinze-Deml, C., Maathuis, M. H., & Meinshausen, N. (2018). Causal Structure Learning. *Annual Review of Statistics and Its Application*, 5, 371–391.



6. Pearl, J. (2009). *Causality: Models, Reasoning, and Inference* (2nd ed.). Cambridge University Press.
7. Scutari, M. (2010). Learning Bayesian Networks with the bnlearn R Package. *Journal of Statistical Software*, 35(3), 1–22.
8. Smith, J. W., et al. (1988). Using the ADAP learning algorithm to forecast the onset of diabetes mellitus. *Proc. Symp. Comput. Appl. Med. Care*.
9. Spirtes, P., Glymour, C., & Scheines, R. (2000). *Causation, Prediction, and Search* (2nd ed.). MIT Press.
10. Textor, J., dkk. (2016). Robust causal inference using directed acyclic graphs: the R package ‘dagitty’. *International Journal of Epidemiology*, 45(6), 1887–1894.